강의 9: 해싱II

강의 개요

- 테이블 더블링
- 분할상환
- Karp-Rabin 문자열 찾기
- 롤링 해시

복습:

체이닝을 이용한 해싱:

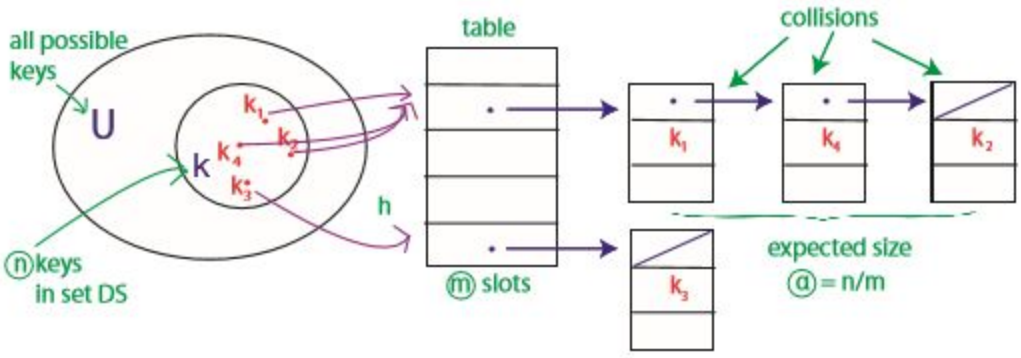

그림 1: 체이닝을 이용한 해싱

기대 비용 (데이터 삽입/삭제/찾기): $\Theta(1 + \alpha)$, 단순 균일 해싱이나 유니버설 해싱이고 해시 함수 h의 실행시간이 $O(1)$라고 가정한다.

나누기 방법:

$$h(k) = k \bmod m$$

m은 이상적으로는 소수이다.

곱하기 방법:

$$h(k) = [(a \cdot k) \bmod 2w] \gg (w - r)$$

a는 2^{w-1} 과 2^w 사이의 무작위 홀수이고, k는 w 비트로 주어졌으며, m = 해시 표의 크기 = 2^r 이다.

해시 표의 크기는 얼마나 커야 하나?

- 항상 $m = \Theta(n)$ 이길 원한다.
- 해시 표를 만들 때는 n이 얼마나 큰지 모른다.
- m이 너무 작으면 느리고, m이 너무 크면 낭비가 된다.

발상:

작은 상수로 시작해 필요에 따라 늘리거나 줄인다.

다시 해싱하기:

해시 테이블을 늘리거나 줄이기 위해서는 해시 함수의 (m, r)도 바뀌어야 한다.

=> 처음부터 다시 해시 테이블을 만들어야 함.

for 항목 in 기존 표: -> for 각 슬롯, for 항목 in 슬롯

새로운 해시 테이블로 삽입

=> $m = \Theta(n)$이면, $\Theta(n + m) = \Theta(n)$ 이다.

늘리는 데 소요되는 시간은?

n이 m이 되면,

- m을 1만 늘린다?

  ⇒ 매번 새롭게 늘려야 한다.

  ⇒ n번의 삽입이 $\Theta(1 + 2 + \cdots + n) = \Theta(n^2)$ 만큼 걸린다.

- m을 2배로 늘린다? $m = \Theta(n)$ still $(r + = 1)$

  ⇒ 2^i 번마다 새롭게 해시 표를 만들어준다.

  ⇒ n번의 삽입이 $\Theta(1 + 2 + 4 + 8 + \cdots + n) = \Theta(n)$ 만큼 걸린다. n은 바로 다음 2의 제곱일 때

- 몇몇의 삽입은 선형시간이 걸리지만, 평균으로는 $\Theta(1)$ 만큼 걸린다.

분할상환 분석

데이터 구조에서 자주 쓰는 기법이다. $1500 월세를 하루에 $50씩 나눠내는 것과 비슷하다.

- k번의 연산 시간 $\leq k \cdot T(n)$ 이면, 연산이 분할상환 실행시간 $T(n)$이 든다.
- "분할상환 $T(n)$"은 대략 "평균적으로" $T(n)$을 의미하고, 모든 연산에 대한 평균이다.

- 예시. 해시 표에 데이터 삽입은 O(1) 분할상환 실행시간이 든다.

다시 해싱으로 돌아와서:

m = Θ(n) ⇒ α = Θ(1) ⇒ 찾기의 기대 실행시간은 $O(1)$ 이다.(단순 균일 해싱이나 유니버설 해싱을 전제로 함.)

데이터 삭제:

기대 실행시간은 $O(1)$ 이다.

- 공간이 n과 같이 커진다. 예시. n번의 삽입, n번의 삭제
- 해결책: n이 m/4로 떨어지면, 해시 표를 반으로 줄인다. ⇒ 삽입과 삭제 둘 다 $O(1)$ 분할상환 시간이 걸린다. - 분석은 더 복잡함. CLRS 17.4 참조

크기 조절이 가능한 배열:

- 같은 기법이 파이썬의 "리스트" (배열)에도 쓰인다.
- ⇒ list.append 와 list.pop 을 $O(1)$ 분할상환 시간으로 할 수 있다.

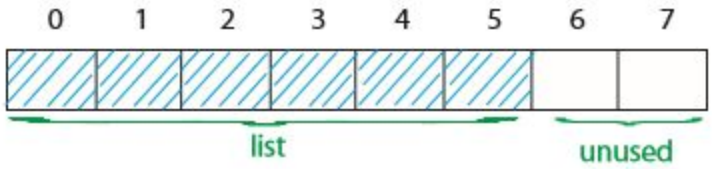

그림 2: 크기 조절이 가능한 배열

문자열 매칭

두 개의 문자열 s와 t가 주어졌을 때, s가 t의 부분 문자열인가? (그리고 그렇다면, 어디에 몇개나 있는가?)

예시. s = '6.006' 이고 t = 전체 받은 메일함 (UNIX에선 'grep')

간단한 알고리즘:

어떠한 (s == t[i : i + len(s)] for i in range(len(t) – len(s)))

— O(|s|) 시간이 각 부분 문자열을 비교할 때 걸린다.

⇒ 총 O(|s|·(|t|−|s|)) 이 걸린다.

= O(|s|·|t|) 2차가 될 수 있다.

그림 3: 문자열 매칭 문제의 간단한 알고리즘 삽화

Karp-Rabin 알고리즘:

- h(s) == h(t[i : i + len(s)]) 를 비교한다.
- 해시 값이 같으면, 문자열도 같을 수 있으니
  - s == t[i : i + len(s)]를 확인한다. 비용 O(|s|)이 걸린다.
  - 확인해서 같다면, 짝을 찾은 것이다.
  - 확인해서 다른 경우는, $\frac{1}{|s|}$ 보다 작은 확률로 발생한다.

    ⇒ i당 기대 실행시간은 $O(1)$ 이다.
- 적당한 해시 함수가 필요하다.
- 기대 시간 = O(|s|+|t|·cost(h))
  - 순진하게 말하면, $h(x)$는 |x| 정도 걸린다.
  - $O(1)$ 안에 실행할 수 있다!
  - 발상: $t[i : i + len(s)] \approx t[i + 1 : i + 1 + len(s)]$.

롤링 해시 ADT

문자열 x가 다음 연산자에 적용된다.

- r(): 문자열 x의 합리적인 해시 함수 h(x)
- r.append(c): 문자열 x 끝에 문자 c를 넣는다.
- r.skip(c): 문자열 x의 첫 문자가 c라는 가정 하에 첫 문자를 지운다.

Karp-Rabin 적용:

```
for c in s: rs.append(c)
for c in t[:len(s)]: rt.append(c)
```

```
    if rs() == rt(): ...
```

이 코드의 첫 부분은 $O(|s|)$ 만큼 걸린다.

```
for i in range(len(s), len(t)):
    rt.skip(t[i-len(s)])
    rt.append(t[i])
    if rs() == rt(): ...
```

코드의 두 번째 부분은 O(|t|) + O(#matches−|s|) 만큼 걸린다.

자료구조:

문자열 x를 a진법으로 쓰여진 여러 자릿수의 수, u로 본다. a는 알파벳의 크기이다. 예시. 256

- r() = u mod p, (이상적으로는 무작위임) 소수 p ≈|s| 또는 |t| (나누기 방법)
- r 은 u가 아닌, u mod p 와 |x| ($a^{|x|}$) 를 가진다.

  ⇒ 작고 빠르게 실행할 수 있다. (u mod p는 하나의 기계 단어와 동일)

- r.append(c): (u·a + ord(c)) mod p = [(u mod p)·a + ord(c)] mod p
- r.skip(c): [u−ord(c)·(a|u|−1 mod p)] mod p

  = [(u mod p)−ord(c)·(a|x−1| mod p)] mod p

6.006 알고리즘의 기초
가을 2011